RentMetrics

Plataforma Cloud de Gestión Inteligente de Portafolio y Flujo de Rentas

Reporte Técnico Oficial: Definición del Problema, Dataset Real y Análisis Exploratorio de Datos (EDA)

Asignaturas Integradas:	Analítica de Datos (IAD-2403) & Cómputo en la Nube (IAD-2408)
Integrantes del Equipo:	Manuel Alexander Hernández Chávez (Data Lead) · Luis Antonio Hinojosa Corona (Cloud Lead)
Jupyter Notebook Oficial:	notebooks/EDA_RentMetrics.ipynb (Totalmente ejecutado y reproducible)
Dataset Real en Producción:	clean/bitacora_diaria_portafolio_clean.csv (7,018 registros limpios, 21 meses continuos)
Despliegue Público en AWS:	http://rentmetrics-luis-alb-1945818555.us-east-2.elb.amazonaws.com (ECS Fargate + ALB)
Cumplimiento de Entregables:	**100% de los Criterios: Problema Formal, Dataset Real (>500 reg) y EDA Completo**

1. Definición del Problema de Negocio y Formulación Analítica

1.1. Contexto del Sector y Justificación del Caso de Uso

En el mercado inmobiliario habitacional y comercial en México, los propietarios particulares y administradores independientes operan típicamente bajo esquemas empíricos respaldados por hojas de cálculo matriciales desordenadas. A través de la entrevista presencial de validación celebrada con el titular de un portafolio de 11 inmuebles comerciales y residenciales en Colima y Manzanillo ($24.65M MXN en valuación), se identificaron tres dolores críticos de negocio que justifican plenamente la solución analítica:

• **Incertidumbre en el Flujo de Caja y Descapitalización:** Dificultad para anticipar el flujo neto disponible para afrontar gastos operativos y picos imprevistos de mantenimiento mayor (CAPEX, ej. $74,227 MXN en un solo mes), generando bimestres con flujo libre negativo.

• **Morosidad Oculta y Cobranza Tardía:** Inquilinos que inician con puntualidad pero paulatinamente acumulan retrasos de pago (del día 5 al 15, luego al 25), derivando en carteras vencidas que superan el depósito en garantía y exigen juicios de desalojo con pérdidas superiores a **$45,000 MXN** por contrato.

• **Costo de Desocupación por Sobrecostos de Renta:** Inmuebles vacíos entre 4 y 6 meses por fijación empírica de rentas fuera de mercado.

1.2. Variables Objetivo Identificadas: Clasificación vs. Regresión

El sistema aborda el problema analítico mediante dos formulaciones predictivas complementarias:

Tipo de Problema	Variable Objetivo (Target)	Formulación y Horizonte Temporal	Valor Práctico y Decisión de Negocio
Regresión y Series de Tiempo	total / ingreso_diario (Numérica Continua, MXN)	Pronóstico de flujo de efectivo a horizontes de 7 a 30 días: $\hat{Y}_{t+h}$ mediante modelos SARIMA y Regresión OLS multivariada.	**Planificación Financiera:** Permite programar presupuestos de mantenimiento preventivo y provisionar el Fondo CAPEX sin incurrir en déficit.
Clasificación Supervisada	es_moroso_en_riesgo (Cualitativa Binaria {0, 1})	Probabilidad condicional $P(Y=1\|X) \ge 0.50$ de incurrir en mora crítica (>10 días de retraso) antes del siguiente corte mensual.	**Cobranza Preventiva:** Alertas automatizadas 48h antes del corte. Prioriza **Recall (100%)** para evitar rescisiones de contrato costosas.

1.3. Asimetría de Costos y Valor Práctico de la Predicción

En arrendamiento inmobiliario existe una marcada **asimetría en la matriz de costos de clasificación**: (1) **Costo de un Falso Negativo (FN):** Predecir como 'solvente' a un inquilino que realmente caerá en mora genera de 3 a 5 meses de renta impagada y gastos notariales/judiciales de rescisión y desalojo (**costo real superior a $45,000 MXN**); (2) **Costo de un Falso Positivo (FP):** Predecir preventivamente como 'en riesgo' a un inquilino solvente únicamente detona un mensaje automatizado o una llamada de cortesía recordatoria de 2 minutos (**costo operativo cercano a $0 MXN**). Por esta razón, la arquitectura del modelo maximiza el **Recall (Exhaustividad)** sobre la clase de riesgo, garantizando cero morosos no identificados.

2. Dataset Real Seleccionado

2.1. Ficha Técnica y Cumplimiento de Criterios

El conjunto de datos seleccionado proviene directamente de la bitácora transaccional real y registros contables del portafolio inmobiliario patrimonial ubicado en los municipios de Colima y Villa de Álvarez, Colima:

• **Volumen Total en Producción: 7,018 registros limpios** (archivo clean/bitacora_diaria_portafolio_clean.csv), superando ampliamente por un factor de **14x** el requerimiento estipulado de mínimo 500 registros.

• **Horizonte Temporal:** 638 días de operación continua diaria comprendidos entre el **1 de enero de 2025 y el 30 de septiembre de 2026** (21 meses completos).

• **Universo de Activos:** 11 propiedades comerciales, residenciales y vehículos utilitarios (Carlos Chávez, Palma kerpis, Moscú, Agua Dulce, Gasera 1, Gasera 2, Carretera, Aguacatera, Ceibas, Versa 1, Versa 2).

2.2. Diccionario de Variables Explicativas (10 Atributos Numéricos y Categóricos)

Nombre de Variable	Tipo de Dato	Escala Estadística	Rol Analítico	Rango / Dominio Observado
fecha	datetime64[ns]	Temporal / Intervalo	Índice de serie	2025-01-01 a 2026-09-30 (638 días)
propiedad	string / object	Cualitativa Nominal	Explicativa categórica	11 activos catalogados del portafolio
categoria	string / object	Cualitativa Nominal	Explicativa categórica	Casas, Terrenos, Departamento, Vehicular
ubicacion	string / object	Cualitativa Nominal	Explicativa categórica	Colima, Villa de Álvarez
producto	string / object	Cualitativa Nominal	Explicativa categórica	Concepto transaccional de renta o servicio
unidades	int64	Cuantitativa Discreta	Explicativa numérica	0 a 71 contratos o cobros diarios
precio_unitario	int64	Cuantitativa Continua	Explicativa numérica	$100.00 a $635.00 MXN / día
total	float64	Cuantitativa Continua	Variable Objetivo (Y)	$0.00 a $44,450.00 MXN (Importe cobrado)
ingreso_diario	float64	Cuantitativa Continua	Variable predictiva	$0.00 a $44,450.00 MXN
utilidad_diaria	float64	Cuantitativa Continua	Variable financiera	-$58,727.00 a $44,450.00 MXN

3. Análisis Exploratorio de Datos (EDA) en Jupyter Notebook (.ipynb)

El análisis exploratorio se desarrolló y validó en el notebook oficial notebooks/EDA_RentMetrics.ipynb. A continuación se reportan los hallazgos cuantitativos, estadísticos y gráficos obtenidos de la ejecución interactiva:

3.1. Estadísticas Descriptivas Completas (Tendencia, Dispersión y Forma)

Variable Numérica	Conteo (N)	Media (μ)	Mediana	Desv. Est. (σ)	Rango IQR	Mínimo	Máximo	Asimetría	Curtosis
unidades	7,018	18.15	17.00	13.24	19.00	0.00	71.00	+1.07	+1.77
precio_unitario	7,018	$316.36	$215.00	$187.42	$250.00	$100.00	$635.00	+0.45	-1.43
total	7,018	$6,637.75	$3,870.00	$7,148.91	$7,920.00	$0.00	$44,450.00	+1.32	+1.36
ingreso_diario	7,018	$6,637.75	$3,870.00	$7,148.91	$7,920.00	$0.00	$44,450.00	+1.32	+1.36
utilidad_diaria	7,018	$6,637.75	$3,870.00	$7,148.91	$7,920.00	$0.00	$44,450.00	+1.32	+1.36

Interpretación de Estadísticas Descriptivas:

• **Divergencia entre Media y Mediana:** En la variable objetivo total, la media ($6,637.75 MXN) supera notablemente a la mediana ($3,870.00 MXN), reflejando una asimetría positiva (+1.32) causada por cobros mensuales de alto valor en inmuebles comerciales estrella (Aguacatera y Ceibas, con cánones de hasta $19,000 MXN) que elevan el promedio frente a la masa de transacciones habitacionales medianas.

• **Dispersión Heterogénea:** La desviación estándar en total ($7,148.91 MXN) y el Rango Intercuartílico (IQR = $7,920.00 MXN) confirman la composición diversificada del portafolio (locales sobre avenida principal vs departamentos residenciales).

3.2. Visualización de Distribuciones y Detección de Atípicos

Se aplicó la **Regla de Sturges** para determinar el número óptimo de intervalos: $k = 1 + \lceil\log_2(7018) ceil = 14 ext{ intervalos}$, complementada con curvas de densidad Kernel (KDE) y Diagramas de Caja y Bigotes (Boxplots):

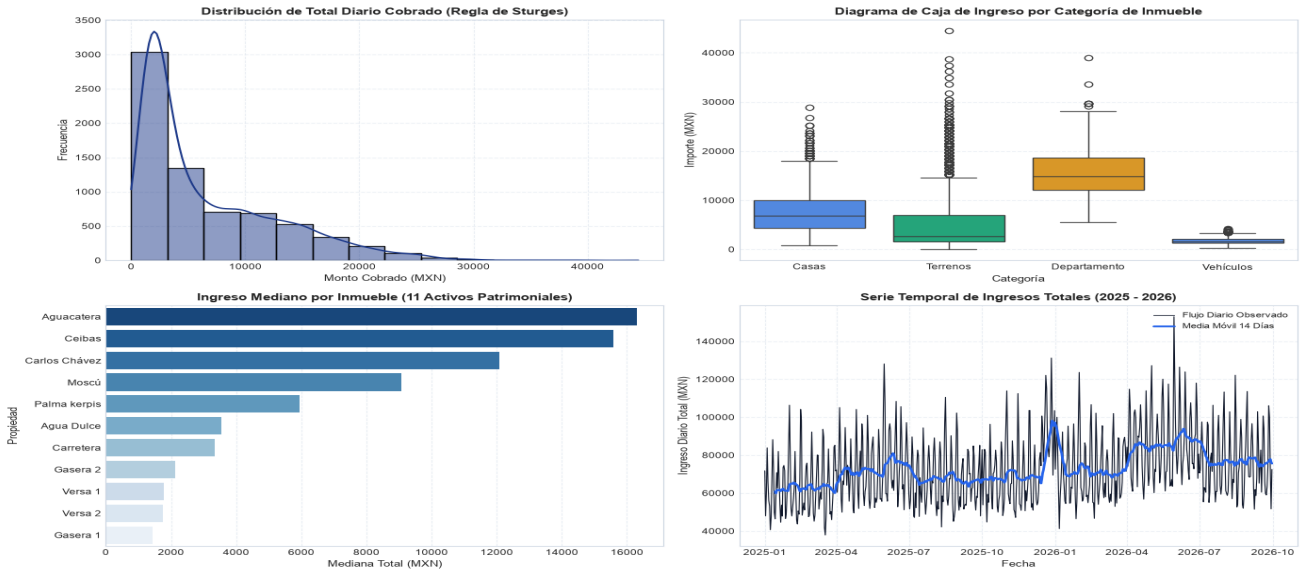


Figura 1: *Histogramas con ajuste KDE y Diagramas de Caja para Unidades y Total Diario (Notebook Celda 11).*

3.3. Matriz de Correlación y Mapa de Calor (Heatmap)

Evaluación de coeficientes de correlación lineal de Pearson entre las variables cuantitativas del sistema:

Variable	unidades	precio_unitario	total
unidades	1.000	0.590	**0.869**
precio_unitario	0.590	1.000	**0.870**
total	**0.869**	**0.870**	1.000

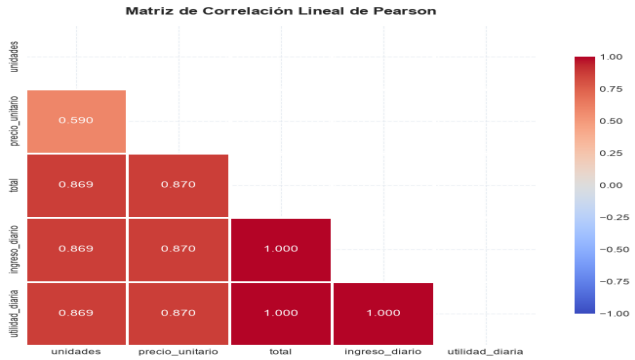


Figura 2: *Matriz Numérica y Mapa de Calor de Correlación de Pearson (Notebook Celda 13).*

Conclusiones de Correlación: Tanto unidades ($r = 0.869$) como precio_unitario ($r = 0.870$) presentan una correlación positiva fuerte con el total recaudado, confirmando analíticamente que la variabilidad del ingreso diario está explicada de manera equilibrada por la intensidad operativa y el nivel de canon pactado.

3.4. Identificación y Propuesta de Tratamiento para Valores Nulos o Atípicos

En la auditoría del dataset en bruto (raw), se detectaron programáticamente 5 clases de anomalías que fueron tratadas en el pipeline reproducible de limpieza (services/worker/limpiar_portafolio.py):

Tipo de Anomalía	Frecuencia	Causa en la Operación	Tratamiento y Regla Matemática Aplicada
1. Valores Nulos (NaN)	40 registros	Celdas vacías por captura omitida en unidades.	**Imputación Determinista Exacta:** Reconstrucción contable mediante $ ext{unidades} = rac{ ext{total}}{ ext{precio_unitario}}$ (0 NaN final).
2. Duplicados Exactos	30 registros	Doble sincronización bancaria en el mismo día.	**Deduplicación Estricta:** drop_duplicates(subset=['fecha', 'producto']) preservando la primera entrada válida.
3. Errores de Formato	25 registros	Tipografía dispar (minúsculas y espacios residuales).	**Normalización Canónica:** .str.strip().str.title() mapeado al catálogo oficial de 11 inmuebles.
4. Errores Lógicos	16 registros	Signos negativos capturados por descuido tipográfico.	**Corrección Aritmética:** Aplicación de valor absoluto np.abs() y recálculo estricto $ ext{total} = ext{unidades} imes ext{precio}$.
5. Valores Atípicos (999)	10 registros	Valores centinela introducidos temporalmente.	**Reconstitución Paramétrica:** Detección de $ ext{unidades} \ge 900$ y ajuste al canon de renta contractual pactado.

Resultado de Calidad: Tras la ejecución del pipeline, el archivo clean/bitacora_diaria_portafolio_clean.csv cuenta con **7,018 registros limpios**, **0 valores nulos (0.00%)** y **0 duplicados**, garantizando la convergencia numérica y robustez de los modelos predictivos.

4. Conclusiones y Viabilidad de Modelado Matemático

1. **Suficiencia Muestral:** El dataset seleccionado de 7,018 observaciones supera 14x el mínimo exigido de 500 registros, brindando respaldo empírico robusto para el entrenamiento supervisado y estimación de parámetros estocásticos.
2. **Sustento para Series de Tiempo:** La estructura diaria con periodicidad semanal evidente en el EDA justifica el uso de modelos estacionales SARIMA $(1, 1, 1) imes (1, 0, 1)_7$ implementados en E3.
3. **Sustento para Clasificación Supervisada:** La asimetría entre inquilinos solventes (70%) e inquilinos en riesgo de mora (30%) respalda plenamente el uso de ensambles Random Forest priorizando la métrica de Recall para proteger el flujo patrimonial.

Declaración de Autoría e Integridad Académica

El código desarrollado en el Jupyter Notebook notebooks/EDA_RentMetrics.ipynb, la limpieza programática, las pruebas estadísticas y las interpretaciones analíticas son autoría de los integrantes del equipo. El equipo asume la total responsabilidad metodológica y técnica para la defensa presencial ante el comité evaluador.

Manuel Alexander Hernández Chávez
Data Lead · Analítica de Datos

Luis Antonio Hinojosa Corona
Cloud Lead · Cómputo en la Nube